

Regresja liniowa - to jedna z podstawowych metod statystycznych i uczenia maszynowego, która służy do modelowania zależności między zmiennymi. Regresji używa się, aby przewidzieć wartość zmiennej zależnej (cecha ilościowa)

Wzór ogólny: wektor wag

$$\hat{y}(\beta, x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_N x_N$$

przewidywana zmienna/cecha \hat{y} zmienna niezależna (posiadane dane) x wynik \hat{y} zależy od danych wejściowych x oraz od wag β

$$\beta = [\beta_0, \beta_1, \beta_2, \dots, \beta_N]$$


$$X = [x_1, x_2, x_3, \dots, x_N]$$

! Uwaga:

posiadane dane wejściowe nie ulegają zmianie - są to wartości stałe. W celu poprawy modelu można zmieniać tylko wektor wag.

Przypadek 2D:

$$\hat{y} = \beta_0 + \beta_1 x \leftarrow \text{równanie proste}$$





prosta, która najlepiej przybliża chmurę danych, inaczej przestrzeń danych

Przypadek 3D:

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 y \rightarrow \text{inaczej} \rightarrow \hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

\leftarrow równanie płaszczyzny



Przypadek LD:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 \leftarrow \text{równanie hiperplaszczyny w przestrzeni LD}$$

Ponieważ regresja liniowa opisuje zależność liniową, to hiperplaszczyna jest „płaska” w danym wymiarze.

Zmienna zależna y jest opisana poprzez trzy zmienne niezależne

	Hours_Studied	Attendance	Parental_Involvement	Access_to_Resources	Extracurricular_Activities	Sleep_Hours
0	23	84	Low	High	No	7
1	19	64	Low	Medium	No	8
2	24	98	Medium	Medium	Yes	7
3	29	89	Low	Medium	Yes	8
4	19	92	Medium	Medium	Yes	6

Gender	Exam_Score
Male	67
Female	61
Male	74
Male	71
Female	70

x_j
Wartość na drugiej współrzędnej „wektora” x_j

Zmienne niezależne

$x_j \leftarrow$ konkretny wiersz
dalej oznaczanie x_j

Zmienna zależna

$$\hat{y} = \beta_0 + \beta_1 \cdot \text{Hours_Studied} + \beta_2 \cdot \text{Attendance} + \beta_3 \cdot \text{Parental_Involvement} + \dots$$

Przykład dla 1 wiersza (indeks 0)

naależy zamienić na wartości numeryczne

$$\hat{y} = \beta_0 + \beta_1 \cdot 23 + \beta_2 \cdot 84 + \beta_3 \cdot 1 + \dots$$

Zakładając, że Low=1, Medium=2, High=3

Jak ustalić wartości wag β ?

- Na początku zamieniać wagi wartościami losowymi (istnieją sposoby bardziej przemyślanej inicjalizacji)
- Rozpocząć proces uczenia maszynowego, którego celem jest otrzymanie/nauczenie się zestawu najlepszych wag.

Wiecej na ten temat zostanie powiedziane w przyszłości

Aby móc rozwijać się/uczyć się potrzeba świadomości o popełnianych błędach. W przypadku tematu uczenia maszynowego wprowadza się funkcję strat/ błąd
Oznaczona najczęściej floss, cost

Pozostając przy regresji liniowej:

$$f_{\text{loss}}(\hat{y}, y) = \sum (\hat{y}(\beta \cdot x^{(j)}) - y^{(j)})^2$$

Suma po wszystkich obserwacjach (punktach)

Wartość przewidziana przez model

Zwróć uwagę, że zastosowano górny indeks

Rozważmy dane z tabeli zamieszczonej wyżej:

tutaj nie ma exam_score

$$\hat{y}(\beta, x^0) = \beta_0 + \beta_1 \cdot 23 + \beta_2 \cdot 84 + \beta_3 \cdot 1 + \dots$$

przewidyujemy exam_score dla pierwszej obserwacji

$$\begin{aligned} y(x^0) &= 67 \\ y(x^1) &= 61 \end{aligned} \quad \left. \begin{array}{l} \text{Rzeczywiste} \\ \text{wartości} \\ \text{exam_score} \end{array} \right\}$$

$$\hat{y}(\beta, x^1) = \beta_0 + \beta_1 \cdot 19 + \beta_2 \cdot 64 + \beta_3 \cdot 1 + \dots$$

Załóżmy, że $\hat{y}(\beta, x^0) = 65$, wtedy błąd dla obserwacji x^0 wynosi

$$(\hat{y}(\beta, x^0) - y(x^0))^2 = (65 - 67)^2 = 4$$

przewidywanie mała różnica, dobra

Teraz niech $\hat{y}(\beta, x^1) = 52$, wtedy błąd

$$(\hat{y}(\beta, x^1) - y(x^1))^2 = (52 - 61)^2 = 81$$

w tym przypadku przewidywanie jest już znacznie gorsze

Dlatego błąd zawsze musi uwzględniać wszystkie dane wejściowe/ treningowe

Uczenie maszynowe w omawianym przypadku to rozwiązanie zadania

$$\min_{\beta} \left(\sum_j \|\hat{y}(\beta, x^j) - y(x^j)\|_2^2 \right)$$

znaleźć wartość wektora wag β dla którego podany wyrażenie przyjmuje wartość najmniejszą.

Co oznacza symbol $\|\cdot\|$?

$\|\cdot\| \leftarrow$ to odzworowanie nazywane norma (norma)

$$\|\cdot\|: X \rightarrow [0, \infty)$$

przestrzeń liniowa (wektorowa) nad ciałem K lub rzeczywistych lub zespolonych

Norma to uogólnienie pojęcia długości wektora, jednak wystarczy rozumieć, że norma to odległość danego elementu przestrzeni wektorowej od początku tej przestrzeni. Istnieje wiele różnych sposobów mierzenia odległości, czyli istnieje wiele norm, dlatego czasami można spotkać dodatkowe symbole przy $\|\cdot\|$, np. $\|\cdot\|_2$ lub $\|\cdot\|_p$

$$\|a\|_2 = \sqrt{\sum_k a_k^2}, \quad \text{np. } \vec{a} = \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix} \quad \|\vec{a}\|_2 = \sqrt{3^2 + 2^2 + 1^2} = \sqrt{14}$$

$$\|\vec{a}\|_2^2 = \left(\sqrt{3^2 + 2^2 + 1^2} \right)^2 = 3^2 + 2^2 + 1^2 = 14$$

Sumę $\sum_j (\hat{y}(\beta, x^j) - y(x^j))$ można zapisać bardziej zgrabnie, za pomocą notacji macierowej

Niech $X = \begin{bmatrix} 1 & x_1^0 & x_2^0 & x_3^0 & \dots & x_m^0 \\ 1 & x_1^1 & x_2^1 & x_3^1 & \dots & x_m^1 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^n & x_2^n & x_3^n & \dots & x_m^n \end{bmatrix}$

$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}$

$y = \begin{bmatrix} y(x^0) \\ y(x^1) \\ \vdots \\ y(x^n) \end{bmatrix}$

Wtedy $(X\beta - y) = e$ ← wektor zawierający wartości błędów na każdej współrzędnej

$$\|e\|_2^2 = e_1^2 + e_2^2 + e_3^2 + e_4^2 + \dots + e_n^2$$

$$e = \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ \vdots \\ e_n \end{bmatrix}$$

Zatem można zapisać:

$$\min_{\beta} \|X\beta - y\|_2$$

Przykład dla danych z tabeli ↑

Parental-Involvement

Hours Studied ↓ Attendance ↓ Access to Resources

$X = \begin{bmatrix} 1 & 23 & 84 & 1 & 3 & \dots \\ 1 & 19 & 64 & 1 & 2 & \dots \\ 1 & 24 & 98 & 2 & 2 & \dots \\ 1 & 29 & 89 & 1 & 2 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{bmatrix}$

← !brak exam-score

exam-score

$y = \begin{bmatrix} 67 \\ 61 \\ 74 \\ 71 \\ \vdots \end{bmatrix}$

$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \end{bmatrix}$

do

ustaleń w procesie uczenia maszynowego